



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Progetto di Operational Analytics

Lucia Castellucci, Luca Samorè
{lucia.castellucci2, luca.samore}@studio.unibo.it
a.a 2025/26

Cosa sono le wavelet?

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right)$$

- Una **wavelet** è una “piccola onda”: una funzione oscillante, localizzata nel tempo, con energia finita e valore medio nullo.
- Da una wavelet madre $\psi(t)$ si ottengono versioni scalate e traslate: il parametro a modifica la scala della wavelet, mentre b ne determina la posizione nel tempo.
- Rispetto alle onde sinusoidali di Fourier, le wavelet permettono di individuare sia la scala di un fenomeno sia il momento in cui si verifica.

Trasformata wavelet continua (CWT)

$$W_x(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{+\infty} x(t) \psi^* \left(\frac{t-b}{a} \right) dt$$

- La CWT misura quanto il segnale $x(t)$ assomiglia alla wavelet posizionata nel punto b e osservata alla scala a
- Valori piccoli di a evidenziano variazioni rapide; valori grandi evidenziano movimenti più lenti.
- Il simbolo $*$ indica il complesso coniugato; con wavelet reali, come Haar, non modifica il calcolo.
- La CWT considera tutte le possibili scale e posizioni: è molto informativa, ma produce molti coefficienti.

Trasformata wavelet discreta (DWT)

$$W(j, k) = \frac{1}{\sqrt{2^j}} \sum_{n=-\infty}^{+\infty} x[n] \psi^* \left(\frac{n - k2^j}{2^j} \right)$$

- La DWT utilizza scale e posizioni discrete: j indica il livello di decomposizione, k la posizione e n l'osservazione della serie.
- La serie viene separata mediante filtri in un'approssimazione, che descrive i movimenti lenti, e in dettagli, che descrivono le variazioni più rapide.
- Ripetendo la decomposizione sull'approssimazione si ottiene un'analisi multirisoluzione.
- Con una decomposizione di livello 2:

$$x_t = A2_t + D2_t + D1_t$$

dove $A2$ è la componente lenta, $D2$ quella intermedia e $D1$ quella più rapida.

Wavelet e forecasting: approccio tradizionale

- Le wavelet non producono direttamente una previsione: trasformano la serie in componenti che rappresentano movimenti lenti e variazioni più rapide.
- L'approccio classico segue tre passaggi: **decomposizione della serie, previsione separata delle componenti e ricombinazione delle previsioni.**
- Ogni componente può essere prevista con modelli come ARIMA, reti neurali o modelli autoregressivi, scegliendo il previsore più adatto alla sua dinamica.
- Conejo et al. (2005) applicano questo schema ai prezzi dell'elettricità: scompongono la serie con le wavelet, prevedono le componenti con ARIMA e ricostruiscono il forecast finale.

Evoluzione dello stato dell'arte

- **mWDN:** la decomposizione wavelet viene inserita direttamente in una rete neurale. Il modello impara quali componenti temporali sono più utili per la previsione. ([Wang et al., 2018](#)).
- **WaveToken:** i coefficienti wavelet vengono trasformati in simboli, chiamati *token*. Un modello autoregressivo impara poi a prevedere i token futuri e, da questi, la serie. ([Masserano et al., ICML 2025](#)).
- **WEITS:** le diverse scale della serie vengono elaborate separatamente e poi combinate. La struttura permette anche di osservare quali componenti hanno contribuito maggiormente alla previsione ([Guo et al., 2026](#)).
- L'evoluzione è quindi passata da una decomposizione fissa prima del forecasting a modelli che integrano le wavelet e imparano automaticamente come utilizzarle.

Il nostro modello: Wavelet + AutoReg

- Abbiamo usato la wavelet **Haar**, con livello 2 e modalità *periodization*. La serie viene così separata nelle componenti *A2*, *D2* e *D1*.
- *A2* rappresenta l'andamento più lento, mentre *D2* e *D1* descrivono oscillazioni progressivamente più rapide.
- Ogni componente viene prevista separatamente con **AutoReg(12)**, utilizzando i dodici valori precedenti.
- Le tre previsioni vengono infine sommate:

Forecast finale = Forecast A2 + Forecast D2 + Forecast D1

Valutazione del modello

- La stessa configurazione è stata applicata a **10 serie M3 e 5 serie M4**, mantenendo gli ultimi 12 mesi come test.
- Wavelet+AutoReg è stato confrontato con Naive stagionale, AutoReg, SARIMA e XGBoost, usando soprattutto il **MASE**.
- Ha ottenuto un MASE medio di **0,893**: migliore di XGBoost (**1,049**) e Naive stagionale (**1,198**), ma leggermente peggiore di SARIMA (**0,882**) e AutoReg (**0,818**).
- Il metodo wavelet ha vinto una serie su 15: è quindi competitivo, ma la decomposizione non garantisce un miglioramento sistematico.

Esperimenti aggiuntivi e scelta finale

- Abbiamo sostituito Haar con **db2** e **db4**, mantenendo invariati livello, modalità e AutoReg. Haar è risultata migliore in 14 serie su 15; db2 e db4 hanno prodotto previsioni molto instabili in diverse serie.
- Abbiamo poi sostituito AutoReg sulle componenti: SARIMA ha ottenuto un MASE di **0,930**, ARMA **1,429** e ARIMA **1,546**, contro **0,893** di AutoReg.
- Abbiamo quindi mantenuto **Haar + AutoReg(12)**: è risultata la soluzione più accurata, stabile, veloce e semplice da spiegare tra quelle sperimentate.